

Segmentation d'images médicales par apprentissage profond : architectures et stratégies d'augmentation de données



Présentation du stage recherche

Master *Sciences et Technologies*,
Mention *Informatique*,
Parcours IASD

Auteur

Ibrahim AL AYOUBI

Superviseurs

Jinan CHARAFEDDINE

Nancy KOZAH

Lieu de stage

DVRC - Pole Léonard de Vinci, Paris

Résumé

Ce stage de fin d'études, réalisé dans le cadre du Master 2 Intelligence Artificielle et Science des Données, s'inscrit dans une problématique de recherche portant sur l'amélioration des performances des modèles de segmentation d'images médicales par apprentissage profond. La segmentation médicale constitue en effet une tâche fondamentale dans de nombreuses applications cliniques, telles que l'identification de structures anatomiques, l'aide au diagnostic, la quantification de régions d'intérêt ou encore la planification thérapeutique. Cependant, la variabilité des données médicales, la complexité des structures à segmenter et la faible disponibilité d'annotations de qualité rendent cette tâche particulièrement difficile.

Dans ce contexte, les travaux menés durant ce stage se concentrent principalement sur l'étude comparative de plusieurs méthodes d'augmentation de données appliquées à la segmentation d'images médicales. L'objectif est d'analyser l'influence de différentes stratégies d'augmentation avancées, notamment **HSMix**, **Guided Mixup**[17], **CutMix**[16], ainsi que d'autres approches guidées par le contenu spatial ou structurel des images, sur la robustesse, la capacité de généralisation et la précision des modèles. Au-delà de l'évaluation de méthodes existantes, ce travail vise également à concevoir et proposer une nouvelle méthode d'augmentation adaptée aux spécificités de la segmentation médicale, puis à en mesurer l'apport expérimentalement.

L'étude est conduite sur plusieurs architectures représentatives de l'état de l'art, couvrant à la fois des approches convolutionnelles classiques, des modèles hybrides et des architectures fondées sur les transformers. Parmi les modèles considérés figurent notamment **U-Net**[10], **DeepLab**[3], **TransUNet**[2], **HiFormer**[14], **DINO U-Net**[6], ainsi que d'autres variantes pertinentes pour la segmentation dense. Cette diversité architecturale permet d'évaluer dans quelle mesure l'efficacité des stratégies d'augmentation dépend du backbone utilisé, et d'identifier les combinaisons les plus performantes entre méthodes d'augmentation et modèles de segmentation.

Une attention particulière est accordée à l'évaluation expérimentale rigoureuse des différentes approches, tant sur les métriques globales de segmentation que sur leur aptitude à mieux préserver les contours et les détails fins des structures anatomiques. En effet, dans le domaine médical, la qualité de délimitation des frontières revêt une importance majeure, car elle conditionne directement la fiabilité de l'analyse clinique qui peut en découler. L'un des enjeux du stage consiste ainsi à déterminer si certaines techniques d'augmentation permettent d'améliorer non seulement les performances globales, mais également la précision locale des segmentations.

Les travaux réalisés ont permis de mettre en place un protocole expérimental complet intégrant l'entraînement, l'évaluation et l'analyse comparative de plusieurs modèles sous différentes configurations d'augmentation. Ce cadre méthodologique constitue une base solide pour étudier de manière systématique l'apport de chaque stratégie et pour situer la méthode proposée par rapport aux approches existantes.

Ainsi, ce stage a pour ambition de contribuer au développement de méthodes de segmentation médicale plus robustes, plus généralisables et mieux adaptées aux contraintes des données cliniques, en s'appuyant sur une analyse approfondie des techniques d'augmentation de données et sur leur évaluation sur plusieurs architectures majeures du domaine.

Table des matières

Table des matières	v
1 Introduction	1
2 Contexte du stage et objectifs	3
2.1 Présentation de la structure d'accueil	3
2.2 Problématique	3
2.3 Objectifs du stage	3
3 État de l'art	5
3.1 Segmentation d'images médicales par apprentissage profond	5
3.2 Architectures de référence	5
3.3 Rôle de l'augmentation de données	6
4 Données, outils et environnement expérimental	7
4.1 Jeu de données utilisé	7
4.2 Classes segmentées	7
4.3 Prétraitement	7
4.4 Environnement logiciel	8
4.5 Organisation du pipeline expérimental	8
5 Méthodologie	9
5.1 Formulation du problème	9
5.2 Fonctions de coût	9
5.3 Métriques d'évaluation	9
5.4 Protocole expérimental	10
6 Architectures étudiées	11
6.1 U-Net	11
6.2 TransUNet	11
6.3 U-NeXt	11
6.4 DeepLabV3+	11

6.5	EfficientUNet	12
6.6	HiFormer	12
6.7	Perspectives et travaux futurs	12
7	Stratégies d'augmentation de données	13
7.1	Motivation	13
7.2	Méthodes d'augmentation étudiées	13
7.3	Vers des augmentations guidées par la structure de l'image	14
7.4	Développement de notre propre méthode d'augmentation	14
8	Résultats et analyses	15
8.1	Protocole expérimental	15
8.2	Résultats quantitatifs globaux	15
8.3	Analyse des résultats	16
8.4	Analyse qualitative	16
8.5	Discussion	17
9	Travaux futurs : implémentation de nouvelles architectures et extension multi-datasets	19
10	Conclusion et perspectives	21
	Bibliographie	23

Introduction

L'imagerie médicale occupe une place essentielle dans la pratique clinique actuelle. Des modalités telles que le scanner, l'IRM ou l'échographie produisent une grande quantité d'images dont l'analyse reste complexe, longue et parfois sujette à une variabilité entre experts. Dans ce contexte, la segmentation d'images médicales constitue une étape clé, puisqu'elle permet de délimiter automatiquement organes, tissus ou lésions, et intervient dans de nombreuses applications comme l'aide au diagnostic, le suivi de pathologies ou la planification thérapeutique.

Les avancées récentes en apprentissage profond ont considérablement amélioré les performances en segmentation, notamment grâce aux réseaux convolutifs et aux architectures hybrides intégrant des mécanismes d'attention ou des transformers. Néanmoins, plusieurs défis persistent, parmi lesquels la faible disponibilité des données annotées, le déséquilibre entre classes, la variabilité anatomique ainsi que la difficulté à segmenter précisément certaines frontières.

C'est dans ce cadre que s'inscrit ce stage réalisé au sein du DVRC – Pôle Léonard de Vinci, Paris. Son objectif est d'étudier et de comparer plusieurs architectures de segmentation médicale, tout en explorant des stratégies d'augmentation de données destinées à améliorer la robustesse des modèles et la qualité des prédictions.

Les travaux menés ont permis de mettre en place un pipeline expérimental complet, d'évaluer plusieurs architectures telles que U-Net[10], TransUNet[2], U-NeXt[13], DeepLabV3+[3], EfficientUNet[12] et HiFormer[14], et d'explorer des méthodes d'augmentation avancées inspirées de CutMix[16], HSMix et de mélanges guidés par super-pixels et cartes de saillance. Ce rapport présente ainsi le contexte du stage, la méthodologie adoptée, les principales architectures étudiées, les stratégies d'augmentation explorées ainsi que les résultats obtenus à ce stade.

Contexte du stage et objectifs

2.1 Présentation de la structure d'accueil

Le stage est réalisé au sein du DVRC – Pôle Léonard de Vinci, à Paris, dans un environnement de recherche appliquée orienté vers l'intelligence artificielle, la vision par ordinateur et l'apprentissage profond. Ce cadre offre des conditions favorables à la mise en place de travaux expérimentaux en segmentation d'images médicales, combinant étude bibliographique, développement logiciel et analyse comparative de modèles.

L'environnement de travail a permis d'aborder à la fois des questions scientifiques, telles que le choix des architectures ou des fonctions de coût, et des aspects plus opérationnels, comme la reproductibilité des expériences, l'organisation du code, la gestion des historiques d'apprentissage et l'évaluation systématique des performances.

2.2 Problématique

La segmentation d'images médicales vise à attribuer à chaque pixel une étiquette correspondant à une structure anatomique ou pathologique. Dans le cas des données volumétriques, cette tâche est rendue difficile par plusieurs facteurs : hétérogénéité des contrastes, bruit d'acquisition, variabilité des formes, faible représentativité de certaines classes, et difficulté de localisation des frontières fines.

Dans ce stage, une attention particulière est portée à la segmentation multi-classes d'organes abdominaux à partir du jeu de données Synapse[4]. Ce problème présente un intérêt pratique et méthodologique important car il combine plusieurs difficultés classiques : déséquilibre inter-classes, proximité anatomique entre structures, tailles d'organes très différentes et frontières parfois peu contrastées.

2.3 Objectifs du stage

Les objectifs du stage peuvent être résumés comme suit :

- étudier les principales architectures de segmentation d'images médicales récentes ;
- implémenter et adapter plusieurs modèles dans un pipeline expérimental homogène ;

- entraîner et évaluer ces modèles sur une tâche de segmentation multi-classes ;
- analyser l'impact de différentes stratégies d'augmentation de données ;
- proposer des pistes d'amélioration ciblant en particulier la robustesse et la qualité des contours segmentés.

Plus concrètement, il s'agit de comparer plusieurs familles d'architectures, d'identifier leurs forces et limites, puis de tester des approches d'augmentation avancées pour améliorer les performances globales et locales des segmentations.

État de l'art

3.1 Segmentation d'images médicales par apprentissage profond

La segmentation sémantique a connu une progression majeure avec l'émergence des réseaux de neurones convolutifs. En imagerie médicale, ces méthodes ont rapidement supplanté les approches classiques basées sur des modèles géométriques, des contours actifs ou des méthodes de seuillage, grâce à leur capacité à apprendre directement des représentations discriminantes à partir des données.

Les réseaux de segmentation reposent généralement sur une architecture encodeur-décodeur : l'encodeur extrait des caractéristiques hiérarchiques de plus en plus abstraites, tandis que le décodeur reconstruit une prédiction dense à la résolution d'origine. Cette stratégie permet de combiner information sémantique et précision spatiale.

3.2 Architectures de référence

U-Net

U-Net est une architecture fondatrice de la segmentation biomédicale. Elle repose sur une structure en "U" composée d'un chemin contractant et d'un chemin expansif, reliés par des connexions de saut (*skip connections*). Ces connexions permettent de réinjecter au décodeur des informations fines issues des couches peu profondes, ce qui améliore la localisation des structures.

Son succès s'explique par sa simplicité, son efficacité sur de petits jeux de données et sa capacité à produire des segmentations précises.

Architectures dérivées et hybrides

De nombreuses variantes ont ensuite été proposées. Attention U-Net[9] introduit des mécanismes d'attention pour sélectionner plus finement les régions pertinentes. U-NeXt[13] cherche à réduire la complexité computationnelle tout en conservant de bonnes performances. TransUNet[2] combine un encodeur de type Vision Transformer avec un




FIGURE 3.1 : Architecture générale de U-Net.

décodeur de style U-Net afin de bénéficier à la fois de la modélisation locale des CNN et de la capture de dépendances globales. HiFormer[14] s'inscrit également dans cette tendance hybride, en exploitant plusieurs niveaux de représentation.

DeepLabV3+[3] adopte une philosophie légèrement différente, fondée sur l'extraction multi-échelle via l'ASPP (*Atrous Spatial Pyramid Pooling*) et un raffinement spatial par décodeur léger. Cette architecture est particulièrement intéressante pour capturer des contextes à plusieurs échelles.

EfficientUNet[12] exploite des encodeurs dérivés des EfficientNet[12], cherchant un compromis entre compacité du modèle et richesse des représentations.

3.3 Rôle de l'augmentation de données

L'augmentation de données constitue un levier essentiel en imagerie médicale, où les jeux de données annotés sont coûteux à produire. Les transformations géométriques et photométriques classiques permettent d'accroître artificiellement la diversité des données d'entraînement, mais elles restent parfois insuffisantes pour traiter des structures anatomiques complexes.

Des méthodes plus avancées, telles que Mixup[17], CutMix[16] ou HSMix, cherchent à combiner des images ou des régions d'images pour créer de nouveaux exemples d'apprentissage. Dans le cadre médical, ces approches doivent être adaptées avec soin afin de préserver la cohérence anatomique.

Les méthodes fondées sur les superpixels sont particulièrement intéressantes, car elles permettent de raisonner sur des régions perceptuellement homogènes plutôt que sur des blocs rectangulaires arbitraires. Lorsqu'elles sont couplées à des cartes de saillance ou à des informations de contour, elles peuvent potentiellement produire des augmentations plus réalistes et mieux adaptées à la segmentation d'organes.

Données, outils et environnement expérimental

4.1 Jeu de données utilisé

Les expériences principales ont été menées sur le jeu de données Synapse[4], couramment utilisé pour la segmentation multi-organes abdominale. Ce jeu de données est constitué d'images issues de volumes médicaux, accompagnées de masques annotés pour plusieurs structures anatomiques.

Dans le cadre de ce stage, les volumes sont exploités sous forme de coupes 2D extraites, ce qui permet de travailler dans un cadre expérimental plus léger tout en conservant une tâche de segmentation multi-classes représentative. Les entrées sont redimensionnées à une taille standard, typiquement 224×224 , afin d'homogénéiser le traitement par les différents modèles.

4.2 Classes segmentées

Le problème étudié correspond à une segmentation multi-classes avec fond et plusieurs organes d'intérêt. Le nombre total de classes manipulées dans les expériences est de 9, incluant le fond. Les métriques reportées se concentrent principalement sur les classes anatomiques d'intérêt, le fond étant généralement exclu du calcul des moyennes.

4.3 Prétraitement

Les étapes principales de prétraitement incluent :

- Chargement des coupes et masques correspondants ;
- Redimensionnement à une taille fixe ;
- Conversion éventuelle des images en format compatible avec les architectures utilisées ;
- Répétition du canal si nécessaire pour certaines architectures pré-entraînées sur des images RGB ;
- Préparation des lots d'entraînement et de test.

4.4 Environnement logiciel

Les implémentations réalisées s'appuient principalement sur l'écosystème Python pour l'apprentissage profond et le traitement d'images. Les bibliothèques utilisées sont les suivantes :

- **PyTorch** : définition des modèles, entraînement et inférence ;
- **Torchvision** : certaines briques de backbone et utilitaires ;
- **NumPy** : manipulation numérique ;
- **SciPy** : opérations de redimensionnement ;
- **OpenCV** : calcul de cartes de saillance dans certaines augmentations ;
- **scikit-image** : génération de superpixels via SLIC[1] ;
- **MedPy** : calcul de métriques, notamment HD95 ;
- **tqdm** : suivi de progression des expériences ;
- **Matplotlib** : visualisation de courbes et résultats.

4.5 Organisation du pipeline expérimental

Une partie importante du stage a consisté à structurer un pipeline homogène permettant de comparer plusieurs architectures dans les mêmes conditions expérimentales. Ce pipeline comprend :

- La gestion des paramètres d'expérience ;
- La création des jeux de données et *dataloaders* ;
- L'instanciation des modèles ;
- L'entraînement avec journalisation des pertes et métriques ;
- L'évaluation sur le jeu de test ;
- La sauvegarde des poids et historiques dans des fichiers CSV ;
- La visualisation des prédictions et des courbes d'apprentissage.

Méthodologie

5.1 Formulation du problème

Soit une image d'entrée $x \in \mathbb{R}^{H \times W \times C}$ et un masque annoté $y \in \{0, \dots, K-1\}^{H \times W}$, où K désigne le nombre de classes. L'objectif du modèle de segmentation est d'apprendre une fonction f_θ paramétrée par θ telle que :

$$f_\theta(x) \rightarrow \hat{y}$$

où $\hat{y}$ représente une prédiction dense à l'échelle du pixel.

5.2 Fonctions de coût

Pour l'apprentissage, une combinaison de perte d'entropie croisée multi-classes et de perte Dice a été utilisée. Ce choix permet de combiner une optimisation pixel à pixel avec une prise en compte explicite du recouvrement entre les régions prédites et les régions de référence.

La fonction de coût globale peut être écrite sous la forme :

$$\mathcal{L} = \mathcal{L}_{CE} + \mathcal{L}_{Dice}$$

L'entropie croisée favorise une bonne classification locale des pixels, tandis que la Dice Loss améliore la cohérence des régions segmentées, ce qui est particulièrement utile dans les contextes de déséquilibre de classes.

Dans plusieurs expériences, des poids de classes ont également été estimés à partir de la distribution des pixels du jeu d'entraînement afin de limiter l'effet de domination des classes majoritaires.

5.3 Métriques d'évaluation

Les performances ont été mesurées à l'aide de plusieurs métriques complémentaires :

- **Dice coefficient** : mesure le recouvrement entre la prédiction et la vérité terrain ;

- **Jaccard / IoU** : mesure également le recouvrement, sous une forme plus stricte ;
- **HD95** : distance de Hausdorff au 95^e percentile, particulièrement informative pour évaluer la qualité des contours.

Le Dice est défini par :

$$Dice = \frac{2|A \cap B|}{|A| + |B|}$$

L'IoU est défini par :

$$IoU = \frac{|A \cap B|}{|A \cup B|}$$

Ces métriques sont calculées par classe, puis moyennées afin d'obtenir des indicateurs macro permettant de comparer globalement les modèles.

5.4 Protocole expérimental

Les modèles sont entraînés sur les données d'apprentissage puis évalués sur un ensemble de test constitué de coupes issues de volumes distincts. L'évaluation est réalisée coupe par coupe, avec redimensionnement si nécessaire pour correspondre à la taille d'entrée des réseaux.

Les expériences sont suivies par :

- la sauvegarde des pertes d'entraînement et de test ;
- la journalisation des métriques macro et par classe ;
- la sauvegarde d'un meilleur modèle selon le meilleur Dice macro sur le test ;
- un arrêt anticipé dans certaines configurations.

Architectures étudiées

6.1 U-Net

U-Net[10] constitue une première base de référence. Son architecture encodeur-décodeur à connexions de saut permet de conserver des détails spatiaux indispensables à la segmentation d'objets fins ou de contours complexes. Dans le cadre de ce stage, U-Net[10] sert de point de comparaison simple, robuste et bien adapté aux jeux de données médicaux.

6.2 TransUNet

TransUNet[2] combine les avantages des CNN et des Vision Transformers. L'idée principale est de capturer des dépendances globales à longue portée dans l'image, ce qui peut être utile lorsque la structure d'intérêt dépend fortement du contexte anatomique global. Son intégration au pipeline a permis d'évaluer l'apport concret d'une composante transformer sur le jeu de données étudié.

6.3 U-NeXt

U-NeXt[13] a été étudié comme architecture plus légère, conçue pour réduire le coût computationnel tout en maintenant de bonnes capacités de segmentation. Cette architecture s'est révélée intéressante dans une perspective de compromis entre précision et efficacité.

6.4 DeepLabV3+

DeepLabV3+[3] repose sur un encodeur enrichi par ASPP, permettant de capturer des informations à différentes échelles grâce aux convolutions dilatées. Son décodeur affine ensuite les prédictions spatiales. Cette architecture est particulièrement adaptée à l'étude de l'impact du contexte multi-échelle sur la segmentation des organes.

6.5 EfficientUNet

EfficientUNet[12] exploite un encodeur de type EfficientNet, ce qui permet de bénéficier d’une extraction de caractéristiques performante avec une complexité relativement maîtrisée. Son étude vise à analyser l’intérêt de backbones modernes et efficaces dans un cadre médical multi-classes.

6.6 HiFormer

HiFormer[14] fait partie des architectures hybrides plus récentes, combinant extraction hiérarchique et modélisation plus globale. Son intégration dans le pipeline a nécessité une adaptation soignée, notamment pour assurer la compatibilité avec les dimensions des entrées et la sortie multi-classes attendue.

6.7 Perspectives et travaux futurs

Dans la poursuite de ce stage, une attention particulière sera portée à l’implémentation from scratch de deux architectures récentes, DINO U-Net[6] et SegDINO[15]. Ces modèles n’ayant, à ce jour, jamais été développés ni évalués dans le cadre des travaux de l’équipe, cette contribution constitue un axe original du stage. L’objectif consistera à concevoir et implémenter intégralement ces architectures, puis à les intégrer au pipeline expérimental afin d’analyser leurs performances en segmentation d’images médicales. Leur étude permettra non seulement d’enrichir la comparaison entre modèles, mais également d’explorer de nouvelles pistes méthodologiques jusqu’ici non investiguées au sein de l’équipe de recherche.

Stratégies d'augmentation de données

7.1 Motivation

Dans le domaine de la segmentation d'images médicales, la quantité de données annotées reste souvent limitée, tandis que la variabilité anatomique, les différences d'acquisition et le bruit inhérent aux images rendent l'apprentissage particulièrement complexe. Dans ce contexte, les stratégies d'augmentation de données occupent une place centrale, car elles permettent d'enrichir artificiellement la diversité des exemples d'entraînement, de réduire le surapprentissage et d'améliorer la capacité de généralisation des modèles.

Cependant, toutes les méthodes d'augmentation ne présentent pas le même intérêt dans un cadre médical. Si certaines transformations simples permettent d'introduire une variabilité utile, d'autres peuvent au contraire produire des exemples peu plausibles sur le plan anatomique ou perturber la cohérence spatiale des structures à segmenter. L'objectif du stage a donc été d'étudier différentes familles de méthodes d'augmentation, depuis les approches classiques jusqu'aux stratégies plus avancées de mélange d'images, afin d'identifier celles qui sont les plus adaptées à la segmentation médicale.

7.2 Méthodes d'augmentation étudiées

Au cours du stage, plusieurs méthodes d'augmentation ont été explorées et intégrées au pipeline expérimental. Les premières expériences se sont appuyées sur des augmentations classiques, telles que les retournements, les rotations, les recadrages, les redimensionnements ou encore les variations d'intensité. Ces transformations constituent une base importante, car elles permettent d'augmenter la variabilité des données d'apprentissage à faible coût computationnel. Néanmoins, leur capacité à enrichir réellement la diversité structurelle des exemples reste limitée.

Dans un second temps, des méthodes d'augmentation plus avancées ont été étudiées, notamment les approches de type mélange entre images. Parmi elles, *CutMix*[16] consiste à remplacer une région d'une image par une région provenant d'une autre image, avec adaptation correspondante des labels. Bien que cette stratégie puisse améliorer la régularisation de l'apprentissage, son principe de découpe rectangulaire reste parfois peu adapté aux structures anatomiques complexes rencontrées en imagerie médicale.

D'autres approches plus structurées ont également été considérées, en particulier *HSMix*, qui repose sur une logique de mélange plus cohérente que les découpages rectangulaires classiques. Ce type de méthode cherche à produire des exemples synthétiques plus réalistes en respectant davantage l'organisation spatiale des images, ce qui le rend particulièrement pertinent pour la segmentation.

7.3 Vers des augmentations guidées par la structure de l'image

Une part importante du travail s'est orientée vers des augmentations fondées sur la structure interne des images. L'idée générale consiste à ne plus effectuer les mélanges de manière arbitraire, mais à s'appuyer sur des régions homogènes et cohérentes du point de vue visuel. Dans cette perspective, les superpixels constituent un outil particulièrement intéressant, puisqu'ils permettent de partitionner une image en zones localement homogènes à l'aide d'algorithmes tels que SLIC[1].

L'utilisation de superpixels dans les stratégies de mélange présente plusieurs avantages. Elle permet d'obtenir des combinaisons plus fines et plus réalistes, tout en préservant davantage la cohérence locale des structures anatomiques. En complément, l'intégration d'informations de saillance ou d'importance visuelle offre la possibilité de guider ces mélanges vers les régions les plus informatives pour l'apprentissage.

7.4 Développement de notre propre méthode d'augmentation

Au-delà de l'étude des méthodes existantes, une contribution importante du stage a consisté à développer et appliquer notre propre stratégie d'augmentation, conçue spécifiquement pour mieux respecter la structure des images médicales. Cette méthode s'appuie sur un mélange guidé à la fois par les superpixels et par des cartes de saillance, afin de construire des exemples synthétiques plus cohérents et potentiellement plus informatifs que ceux produits par des approches classiques.

Le principe général repose sur une segmentation préalable des images en régions homogènes, suivie d'un calcul de poids de mélange tenant compte de l'organisation spatiale des superpixels ainsi que de l'importance relative des régions dans l'image. Ces poids sont ensuite appliqués de manière conjointe aux images et aux labels, de façon à préserver la cohérence entre les données d'entrée et les annotations. Cette approche permet de produire des mélanges plus adaptés aux contraintes de la segmentation médicale, en particulier pour les structures fines et les zones de transition.

Cette méthode a été implémentée dans le pipeline expérimental puis évaluée sur plusieurs architectures de segmentation. Les résultats obtenus ont montré des améliorations intéressantes par rapport à certaines augmentations plus classiques, aussi bien en termes de robustesse que de qualité des segmentations. En particulier, l'approche proposée a permis d'observer de meilleures performances sur plusieurs expériences, ce qui confirme l'intérêt de concevoir des augmentations plus structurées et mieux adaptées au contexte médical.

Résultats et analyses

8.1 Protocole expérimental

Les expériences réalisées jusqu’au moment ont été menées sur le jeu de données *Synapse*[4], largement utilisé pour l’évaluation des méthodes de segmentation d’images médicales abdominales. L’objectif principal de cette partie expérimentale est d’analyser l’impact de notre méthode d’augmentation sur les performances de plusieurs architectures de segmentation, en comparant systématiquement chaque modèle dans deux configurations : une configuration *baseline*, sans augmentation avancée spécifique, et une configuration enrichie par notre propre stratégie d’augmentation.

8.2 Résultats quantitatifs globaux

Le Tableau 8.1 présente les performances obtenues sur *Synapse*[4] en termes de Dice moyen, de Jaccard moyen, de HD95, ainsi que des scores Dice par classe anatomique. Pour chaque architecture, les résultats de la version de base sont comparés à ceux obtenus après intégration de notre méthode d’augmentation.

TABLE 8.1 : Comparaison des performances sur le jeu de données *Synapse*[4] entre les architectures de base et les mêmes architectures entraînées avec notre méthode d’augmentation.

Method	Average performance			DSC (%) for each class							
	DSC (%) $\uparrow$	JAC (%) $\uparrow$	HD95 $\downarrow$	Aorta	Gallbladder	Kidney (L)	Kidney (R)	Liver	Pancreas	Spleen	Stomach
UNet[10]	75.84	68.37	10.82	86.50	64.23	79.84	80.66	87.44	57.25	84.48	66.31
UNet + AUG	77.84	69.48	28.59	87.80	64.36	80.10	81.64	88.35	59.10	83.96	67.88
UNet-EfficientNet-b2[12]	73.25	64.66	10.33	84.37	51.81	83.89	76.02	86.28	51.94	83.88	67.82
UNet-EfficientNet-b2 + AUG	76.36	67.54	31.28	88.47	55.18	85.53	83.64	86.85	58.74	82.69	69.79
UNet-ResNet50	79.28	72.44	6.77	89.96	63.75	86.36	83.11	90.30	61.90	86.64	72.22
UNet-ResNet50 + AUG	79.89	71.79	23.63	89.67	66.97	87.00	86.40	88.13	63.87	87.54	69.53
UNetXt[13]	67.06	58.20	11.44	71.56	47.00	70.70	66.95	92.52	31.52	80.25	62.97
UNetXt + AUG	69.91	59.82	33.72	81.73	48.20	80.20	74.96	84.01	45.45	80.82	63.93
DeepLabv3+[3]	77.79	70.53	6.63	85.06	60.93	85.75	82.75	89.53	59.66	85.03	73.64
DeepLabv3+ + AUG	79.88	71.68	18.56	87.51	61.65	89.49	86.04	90.11	64.88	88.95	70.43
TransUnet[2]	74.26	66.53	8.78	82.34	55.09	84.32	80.61	87.03	54.46	83.71	66.54
TransUnet + AUG	76.35	67.56	30.13	88.03	55.91	87.49	82.53	85.75	56.19	84.15	70.77
HiFormer-B[14]	77.49	69.62	7.27	85.01	62.08	86.48	80.74	88.27	59.87	85.66	71.82
HiFormer-B + AUG	79.26	70.77	18.96	87.74	63.50	86.73	85.20	87.95	60.98	87.16	74.83

8.3 Analyse des résultats

Les résultats obtenus mettent en évidence une tendance générale claire : l'intégration de notre méthode d'augmentation améliore les performances moyennes de segmentation pour l'ensemble des architectures étudiées sur le jeu de données Synapse[4]. Cette amélioration est observée de manière particulièrement nette sur le Dice moyen et le Jaccard moyen, ce qui montre que la stratégie proposée contribue à renforcer la qualité globale du recouvrement entre les prédictions et les annotations de référence.

Parmi les modèles considérés, les meilleures performances en Dice moyen sont obtenues par *UNet-ResNet50 + AUG* avec un score de 79.89%, suivi de très près par *DeepLabv3+ + AUG* avec 79.88% et *HiFormer-B + AUG* avec 79.26%. De manière plus générale, l'ajout de notre méthode d'augmentation permet un gain systématique en Dice sur toutes les architectures testées. Ce comportement est particulièrement intéressant, car il montre que l'approche proposée ne bénéficie pas uniquement à un modèle spécifique, mais présente un effet positif relativement stable sur différents backbones et différentes familles architecturales.

L'analyse par classe confirme également l'intérêt de cette stratégie. Des améliorations sont observées sur plusieurs structures anatomiques, notamment pour la vésicule biliaire, les reins, le pancréas et l'estomac, qui sont souvent plus difficiles à segmenter en raison de leur variabilité anatomique ou de contours plus complexes. Par exemple, pour *DeepLabv3+[3]*, l'augmentation permet une progression notable sur le pancréas (de 59.66% à 64.88%) ainsi que sur les deux reins. De même, pour *TransUnet[2]* et *HiFormer-B[14]*, des gains sont visibles sur la majorité des organes, ce qui suggère que la méthode proposée améliore non seulement la performance globale, mais également la capacité du modèle à mieux délimiter plusieurs structures spécifiques.

Il convient toutefois de noter que l'amélioration n'est pas strictement uniforme sur toutes les classes. Dans certains cas, quelques organes présentent une légère baisse de performance malgré une amélioration globale des scores moyens. Cela reste cohérent avec la complexité intrinsèque de la segmentation multi-organes, où les bénéfices d'une stratégie d'augmentation peuvent varier selon la taille, la forme et la difficulté de chaque structure anatomique.

Concernant la métrique HD95, les valeurs obtenues avec augmentation sont globalement plus élevées que celles des baselines. Comme cette métrique doit être minimisée, cela indique que, malgré l'amélioration des scores de recouvrement moyens, la précision géométrique des frontières n'est pas encore systématiquement meilleure avec la méthode proposée. Ce résultat suggère que notre stratégie d'augmentation améliore la cohérence globale des régions segmentées, mais qu'un travail complémentaire reste nécessaire pour optimiser plus spécifiquement la qualité des contours. Cette observation est particulièrement importante en segmentation médicale, où la précision des frontières peut avoir un impact direct sur l'interprétation clinique.

8.4 Analyse qualitative

Afin de compléter l'analyse quantitative, une comparaison qualitative des segmentations obtenues a également été réalisée. La Figure 8.1 présente des exemples de prédictions

sur le jeu de données Synapse[4] pour deux architectures, *UNet*[10] et *TransUNet*[2], en comparant les résultats obtenus sans augmentation (*W/O*) et avec notre méthode d'augmentation (*W*), par rapport aux annotations de référence (*Ground Truth*). Ces visualisations montrent que l'intégration de la stratégie d'augmentation permet, dans plusieurs cas, d'améliorer la cohérence des régions segmentées ainsi que la délimitation de certaines structures anatomiques. Elles mettent également en évidence que, malgré ces améliorations qualitatives, certaines difficultés persistent au niveau des structures les plus fines ou des frontières complexes.




FIGURE 8.1 : Comparaison qualitative des résultats de segmentation sur plusieurs coupes du jeu de données Synapse[4].

8.5 Discussion

Dans l'ensemble, ces résultats montrent que notre méthode d'augmentation constitue une contribution pertinente pour améliorer les performances de segmentation sur Synapse[4]. Son intérêt principal réside dans sa capacité à produire des gains réguliers sur plusieurs architectures différentes, ce qui témoigne d'une bonne capacité de généralisation de l'approche. Les améliorations observées sur les métriques de recouvrement confirment que cette stratégie enrichit utilement les données d'apprentissage et permet aux modèles d'apprendre des représentations plus robustes.

En revanche, l'analyse du HD95 montre que l'amélioration des performances moyennes ne s'accompagne pas nécessairement d'un meilleur positionnement des frontières. Ainsi, même si la méthode proposée améliore nettement le Dice et le Jaccard, elle devra être approfondie afin de mieux prendre en compte les détails fins et la précision géométrique des contours.

Travaux futurs : implémentation de nouvelles architectures et extension multi-datasets

Dans la continuité des travaux réalisés au cours de ce stage, la prochaine étape consistera à élargir le cadre expérimental par l'implémentation *from scratch* de deux architectures récentes : *DINO U-Net*[6] et *SegDINO*[15]. À ce jour, ces modèles n'ont encore jamais été développés ni évalués dans le cadre des travaux de l'équipe, ce qui confère à cette phase une dimension à la fois exploratoire et innovante.

L'objectif sera, dans un premier temps, de concevoir et d'implémenter intégralement ces architectures, puis de les intégrer au pipeline expérimental déjà mis en place durant le stage. Cette intégration permettra d'étudier leur comportement dans le cadre de la segmentation d'images médicales, en comparaison avec les modèles déjà expérimentés tels que *U-Net*[10], *DeepLabv3+*[3], *TransUNet*[2], *UNeXt*[13] ou encore *HiFormer*[14].

Dans un second temps, une attention particulière sera portée à l'association de ces nouvelles architectures avec les différentes stratégies d'augmentation étudiées au cours du stage. L'objectif est d'évaluer l'effet combiné des architectures de type DINO avec des augmentations avancées, notamment les méthodes de mélange guidé et la stratégie d'augmentation proposée dans ce travail. Cette étude permettra d'analyser dans quelle mesure ces nouveaux modèles peuvent bénéficier de telles augmentations, et si leur capacité de représentation peut être renforcée par un protocole d'apprentissage enrichi.

Enfin, afin de mieux évaluer la robustesse et la généralisabilité des approches développées, les futures expérimentations ne se limiteront pas au seul jeu de données *Synapse*[4]. Les implémentations de *DINO U-Net*[6] et *SegDINO*[15], ainsi que les différentes stratégies d'augmentation, seront testées sur plusieurs jeux de données représentatifs de tâches variées en segmentation médicale, notamment *BraTS18*[8], *ISIC17*[5], *Synapse*[4], *GLAS*[11] et *MoNuSeg*[7]. Ce choix permettra d'étendre l'évaluation à des modalités d'imagerie, des structures anatomiques et des niveaux de difficulté différents, et ainsi de mieux mesurer la capacité de généralisation des méthodes étudiées.

Cette perspective ouvre ainsi un prolongement naturel du stage, en combinant l'exploration de nouvelles architectures, l'étude de stratégies d'augmentation avancées et une validation sur plusieurs jeux de données de référence. Elle permettra de consolider les résultats obtenus jusqu'à présent et d'inscrire ce travail dans une démarche plus large de recherche sur la segmentation médicale robuste et généralisable.

Conclusion et perspectives

Ce stage de fin d'études a porté sur l'étude de la segmentation d'images médicales par apprentissage profond, avec un intérêt particulier pour l'analyse comparative de plusieurs architectures de segmentation et pour l'évaluation de stratégies d'augmentation de données avancées. L'ensemble des travaux réalisés a permis de mettre en place un pipeline expérimental structuré, reproductible et adaptable, dédié à l'entraînement, à l'évaluation et à l'analyse de plusieurs modèles sur des tâches de segmentation multi-organes.

Au cours de ce travail, différentes architectures représentatives de l'état de l'art ont été étudiées et évaluées, allant des modèles convolutionnels classiques aux architectures hybrides intégrant des mécanismes de type transformer. En parallèle, une attention particulière a été accordée aux stratégies d'augmentation de données, en raison de leur rôle central dans l'amélioration de la robustesse et de la capacité de généralisation des modèles. Plusieurs approches ont ainsi été explorées, depuis les augmentations standards jusqu'à des méthodes plus structurées fondées sur les mélanges régionaux, les superpixels et les cartes de saillance.

L'une des contributions importantes de ce stage réside dans la conception et l'intégration d'une méthode d'augmentation propre, développée dans l'objectif de mieux préserver la cohérence anatomique des images tout en enrichissant la diversité des données d'apprentissage. Les résultats expérimentaux obtenus sur le jeu de données *Synapse*[4] ont montré que cette stratégie permet d'améliorer de manière régulière les performances globales de plusieurs architectures, en particulier sur les métriques de recouvrement telles que le Dice et le Jaccard. Ces résultats confirment l'intérêt de concevoir des augmentations plus adaptées aux contraintes spécifiques de la segmentation médicale.

Ainsi, ce stage a permis de poser une base méthodologique et expérimentale solide pour l'étude conjointe des architectures de segmentation et des stratégies d'augmentation de données. Les perspectives ouvertes par ce travail concernent à la fois l'implémentation de nouvelles architectures prometteuses, l'extension à plusieurs jeux de données médicaux et l'approfondissement des approches d'augmentation structurée. Dans cette continuité, le développement futur de *DINO U-Net*[6] et *SegDINO*[15], ainsi que leur évaluation sur des bases telles que *BraTS18*[8], *ISIC17*[5], *Synapse*[4], *GLAS*[11] et *MoNuSeg*[7], constituera une étape importante pour renforcer la portée et la généralisabilité des travaux entrepris.

Bibliographie

- [1] Radhakrishna Achanta, Appu Shaji, Kevin Smith, Aurelien Lucchi, Pascal Fua, and Sabine Süsstrunk. Slic superpixels compared to state-of-the-art superpixel methods. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 34(11) :2274–2282, 2012.
- [2] Jieneng Chen, Yongyi Lu, Qihang Yu, Xin Luo, Ehsan Adeli, Yan Wang, Le Lu, Alan L. Yuille, and Yuyin Zhou. Transunet : Transformers make strong encoders for medical image segmentation. *arXiv preprint arXiv :2102.04306*, 2021.
- [3] Liang-Chieh Chen, Yukun Zhu, George Papandreou, Florian Schroff, and Hartwig Adam. Encoder-decoder with atrous separable convolution for semantic image segmentation. In *European Conference on Computer Vision (ECCV)*, 2018.
- [4] Kenneth Clark, Bruce Vendt, Kirk Smith, et al. The cancer imaging archive (tcia) : Maintaining and operating a public information repository. *Journal of Digital Imaging*, 26(6) :1045–1057, 2013.
- [5] Noel C. F. Codella, Veronica Rotemberg, Philipp Tschandl, et al. Skin lesion analysis toward melanoma detection : A challenge at the 2017 international symposium on biomedical imaging. *ISBI*, 2018.
- [6] Yifan Gao, Haoyue Li, Feng Yuan, Xiaosong Wang, and Xin Gao. Dino u-net : Exploiting high-fidelity dense features from foundation models for medical image segmentation. *arXiv preprint arXiv :2508.20909*, 2025.
- [7] Neeraj Kumar, Ruchika Verma, Sanuj Sharma, et al. A multi-organ nucleus segmentation challenge. *IEEE Transactions on Medical Imaging*, 39(5) :1380–1391, 2020.
- [8] Bjoern H. Menze, Andras Jakab, Stefan Bauer, et al. The multimodal brain tumor image segmentation benchmark (brats). *IEEE Transactions on Medical Imaging*, 34(10) :1993–2024, 2015.
- [9] Ozan Oktay, Jo Schlemper, Loic Le Folgoc, et al. Attention u-net : Learning where to look for the pancreas. *arXiv preprint arXiv :1804.03999*, 2018.

- [10] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net : Convolutional networks for biomedical image segmentation. In *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, 2015.
- [11] Korsuk Sirinukunwattana, Shan E. Ahmed Raza, Yee-Wah Tsang, et al. Gland segmentation in colon histology images : The glas challenge contest. *Medical Image Analysis*, 35 :489–502, 2017.
- [12] Mingxing Tan and Quoc V. Le. Efficientnet : Rethinking model scaling for convolutional neural networks. *Proceedings of the International Conference on Machine Learning (ICML)*, 2019.
- [13] Jeya Maria Jose Valanarasu, Pritesh Patel, et al. Unext : Mlp-based rapid medical image segmentation network. *Medical Image Analysis*, 2023.
- [14] Tianrun Xiao et al. Hiformer : Hierarchical multi-scale representations using transformers for medical image segmentation. *arXiv preprint arXiv :2207.08518*, 2022.
- [15] Sicheng Yang, Hongqiu Wang, Zhaohu Xing, Sixiang Chen, and Lei Zhu. Segdino : An efficient design for medical and natural image segmentation with dino-v3. *arXiv preprint arXiv :2509.00833*, 2025.
- [16] Sangdoo Yun, Dongyoon Han, Seong Joon Oh, Sanghyuk Chun, Junsuk Choe, and Youngjoon Yoo. Cutmix : Regularization strategy to train strong classifiers with localizable features. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2019.
- [17] Hongyi Zhang, Moustapha Cisse, Yann N. Dauphin, and David Lopez-Paz. mixup : Beyond empirical risk minimization. *International Conference on Learning Representations (ICLR)*, 2018.